

Matriz de Costos y Optimización de Modelos de IA

Tarea del Proceso	Modelo de IA Seleccionado	Justificación Técnica de la Elección	Costo Estimado (Por 1M de Tokens)	Ahorro / Beneficio Operativo
Procesamiento de Lenguaje Natural (NLP) <i>(Extracción de datos del correo de reserva)</i>	Google Gemini Flash / Pro <i>(El que uses en tu nodo)</i>	Ideal para tareas de extracción rápida y estructuración de texto no estructurado (como correos de clientes con fechas y comensales). Ofrece una excelente ventana de contexto con baja latencia.	Bajo (aprox. \$0.07 - \$0.50 USD por millón de tokens de entrada según versión)	70% de ahorro frente a modelos pesados, optimizando la ejecución en Make para volumen medio de reservas.
Análisis Masivo o Lotes (Batch) <i>(Opcional para auditoría o reportes)</i>	Google Gemini Flash (Modo Batch)	Pensado para procesar registros históricos o logs acumulados en Airtable fuera de hora pico.	Tarifa reducida al 50% en llamadas por lotes.	50% de reducción adicional en costos operativos si se escalara a cientos de reservas diarias.
Tareas Complejas de Razonamiento	<i>No requerido / Descartado</i>	Para este flujo transaccional de reservas, un modelo de razonamiento avanzado (como Claude 3.5 Sonnet o	Alto (\$3.00 - \$15.00 USD por millón de tokens)	Evita el sobre costo innecesario en tareas repetitivas y estructuradas .

Tarea del Proceso	Modelo de IA Seleccionado	Justificación Técnica de la Elección	Costo Estimado (Por 1M de Tokens)	Ahorro / Beneficio Operativo
(Validación de políticas o excepciones)		GPT-4o) implicaría un costo innecesario de hasta 10 veces más por token sin aportar valor diferencial.		

Conclusión para tu documentación:

*"Para este ecosistema de automatización autónomo se seleccionó la familia de modelos **Google Gemini** a través de Make. La decisión se fundamenta en un análisis de costo-eficiencia: al tratarse de un flujo transaccional de extracción de datos de reservas de correo (nombre, fecha, comensales), Gemini Flash ofrece la velocidad y precisión requeridas con un costo por token significativamente menor que alternativas como GPT-4o, garantizando la viabilidad económica del negocio a escala."*